Introducción a R

Felipe José Bravo Márquez

13 de noviembre de 2013

Motivación

- Diaramente se almacenan masivamente grandes colecciones de datos.
- Ej: La Web, comercio electrónico, datos transaccionales.
- Los computadores se vuelven cada vez más baratos y con mayor poder de procesamiento.
- Analizar estos datos permite encontrar patrones ocultos.
- Un buen uso de los datos puede traer beneficios de negocio. Ej: segmentación de clientes, predicción de demanda.




El proyecto R para la estadística computacional



- R es un ambiente de programación estadístico totalmente gratuito: http://www.r-project.org/
- Permite manipular y almacenar datos de manera efectiva.
- Es un lenguaje de programación completo: variables, loop, condiciones, funciones.
- Provee muchas librerías para realizar distintos tipos de análisis sobre colecciones de datos, ej: visualización de datos, análisis de series temporales, análisis de grafos, análisis de texto.
- Las librerías junto a sus dependencias se encuentra ordenadas en un repositorio llamado CRAN: http://cran.r-project.org/


¿Por qué usar R?

- R es software libre a diferencia de Matlab, SPSS, STATA.
- Esta disponible para muchos sistemas operativos: Windows, MAC OS X, Linux.
- Según la última encuesta de KDnuggets, R es el lenguaje de programación preferido para realizar análisis de datos, minería de datos y ciencia de datos.
- http://www.kdnuggets.com/2013/08/ languages-for-analytics-data-mining-data-science.html



RStudio

- R funciona a través de la línea de comandos.
- Para trabajar en un entorno más amigable usaremos RStudio.
- También es gratis y se puede descargar para distintos sistemas operativos en este link: http://www.rstudio.com/ide/download/desktop



R puede ser usado como una calculadora

```
> 4*5
[1] 20
> 2^3
[1] 8
> exp(-5)
[1] 0.006737947
> log(4)
[1] 1.386294
```

Declarando Variables

Las variables se pueden asignar usando <- , = o la función assign</p>

```
a<-1
b=3
assign("tres",3)
d<-a+b
ver<-T # equivalente a TRUE
pal<-"hola"</pre>
```

- Por convención usamos la primera forma (<-).</p>
- Las variables pueden ser de clase numeric, factor, character, logical, entre otras.
- Para ver el tipo de una variable usamos el comando class.

```
> class(a)
[1] "numeric"
> class(ver)
[1] "logical"
> class(pal)
[1] "character"
```

Funciones

Las funciones se declaran como variables y se crean con la expresión function:

```
suma<-function(a=2,b=1) {
   a+b;
}

fac<-function(n) {
   ifelse(n==1,return(1),return(n*factorial(n-1)))
}</pre>
```

 Los parámetros de la función se pueden declaran con un valor específico para usarlos como valores predeterminados cuando no entregamos valores para esos parámetros:

```
> suma(3,4)
[1] 7
> suma()
[1] 3
```

Las funciones son del tipo function:

```
> class(suma)
[1] "function"
```

Ayuda y el Workspace

Para leer documentación sobre una función usamos help o ?:

```
help(ls)
?ls
#Para un comando particular
help("for")
```

Todas las variables quedan en mi ambiente workspace. Para listarlos se usa el comando objects o ls. Para borrar una variable usamos rm:

```
objects()
ls()
rm(a)
#Para borrarlos todos
rm(list=ls())
```

 Puedo grabar todas mis variables de workspace en un archivo y así recuperar mi trabajo en una sesión futura:

```
save.image("myworkspace.RData")
#Luego lo cargamos
load("myworkspace.RData")
```

Vectores

 Para trabajar con colecciones de elementos declaramos vectores que se construyen con el comando c:

```
edades<-c(21,33,12,34,23,70,90,80,7,29,14,2,88,11,55,24,13,11,56,28,33)
```

 Para obtener el largo de un vector usamos el comando length, luego para obtener la suma de todos los elementos usamos sum:

```
> suma<-sum(edades)
> largo<-length(edades)
> suma
[1] 734
> largo
[1] 21
```

 Si operamos un vector por un escalar este valor se recicla para todos los elementos del vector:

```
> numeros<-c(1,2,3)
> numeros+3
[1] 4 5 6
> numeros*5
[1] 5 10 15
```

Vectores (2)

 Calcular la media y la varianza del vector edades usando los comandos sum y length en base a las siguientes ecuaciones:

$$media(edades) = \frac{\sum_{i=1}^{n} edades_i}{n}$$
 (1)

$$varianza(edades) = \frac{\sum_{i=1}^{n} (edades_i - media(edades))^2}{n-1}$$
 (2)

Vectores (4)

Respuesta:

```
> media<-sum(edades)/length(edades)
> media
[1] 34.95238
> varianza<-sum((edades-media)^2)/(length(edades)-1)
> varianza
[1] 747.9476
```

R dispone de funciones mean y var:

```
> mean(edades)
[1] 34.95238
> var(edades)
[1] 747.9476
```

Vectores (5)

 Cuando construimos vectores con elementos de distinto tipo, R los convierte todos a un tipo único:

```
> c("hola",2,T)
[1] "hola" "2" "TRUE"
> c(TRUE,FALSE,500)
[1] 1 0 500
```

 Los elementos de un vector pueden se declarados con nombres para luego recuperarlos con el comando names:

```
> notas<-c(Juan=4.5,Luis=6.2,Romina=3.9,Felipe=2.8,Mariana=6.7)
> names(notas)
[1] "Juan" "Luis" "Romina" "Felipe" "Mariana"
```

Podemos ordenar un vector usando el comando sort:

```
> names(sort(x=notas,decreasing=T))
[1] "Mariana" "Luis" "Juan" "Romina" "Felipe"
```

Acceso Vectores

R permite acceder a los elmentos de un vector por medio de índices numéricos
 [i]:

```
> notas[1] # primer elemento
Juan
4.5
```

• El índice puede ser otro vector númerico para acceder a más de un elemento:

```
> notas[c(1,5)] # primer y quinto elemento
Juan Mariana
4.5 6.7
```

Si queremos omitir algún elemento usamos índices negativos:

```
> notas[-2] # Todos menos el segundo
Juan Romina Felipe Mariana
4.5 3.9 2.8 6.7
```

• También se pueden acceder a los elementos por sus nombres:

```
> notas[c("Juan","Mariana")] # Sólo Juan y Mariana
Juan Mariana
4.5 6.7
```

Operando Vectores

- Vimos anteriormente que si opero un escalar por un vector, el escalar se aplica a todos los elementos del vector.
- Si tengo ahora dos vectores del mismo largo y los opero, la operación se hace elemento por elemento:

```
a<-c(1,2)
b<-c(3,4)
> a+b
[1] 4 6
> a*b
[1] 3 8
```

Operando Vectores (2)

Si los vectores son de largo distinto, el más pequeño recicla sus elementos:

```
> d<-c(4,5,6,9)
> a+d
[1] 5 7 7 11
> c(a,a)+d
[1] 5 7 7 11
```

 Si el largo del mayor no es múltiplo del largo del menor, recibimos una advertencia:

```
> c(1,2)+c(-9,2,3)
[1] -8 4 4
Warning message:
In c(1, 2) + c(-9, 2, 3):
longer object length is not a multiple of shorter object length
```

Comparando Vectores

```
> menores<-edades<18
> menores
[1] FALSE FALSE TRUE FALSE FALSE FALSE FALSE FALSE TRUE FALSE
[17] TRUE TRUE FALSE FALSE FALSE
```

 Si le damos a un vector un índice de variables lógicas recuperamos los valores donde el índice toma el valor verdadero:

```
> edades[menores]
[1] 12 7 14 2 11 13 11
```

• Ejercicio: calcular el promedio de edad de los elementos mayores de 18 años.

```
mean (edades [edades>=18])
```

Valores Nulos

 En R, los valores faltantes se escriben como NA. Es común que aparezcan cuando leemos datos de alguna base de datos. Algunas funciones no aceptan valores nulos por lo que hay que tenerlos en cuenta.

```
> missing_vector<-c(12,15,NA)
> missing_vector
[1] 12 15 NA
```

Para chequear si una variable es nula usamos el comando is.na:

```
> missing_vector[!is.na(missing_vector)]
[1] 12 15
```

Secuencias

 Para crear un vector formado por una secuencia de números usamos el comando seq:

```
> pares<-seq(from=2,to=20,by=2)
> cuatro_mult<-seq(from=4,by=4,length=100)
> pares
[1] 2 4 6 8 10 12 14 16 18 20
```

También se pueden crear usando el operador (:):

```
> 1:10
[1] 1 2 3 4 5 6 7 8 9 10
> seq(1,10,1)
[1] 1 2 3 4 5 6 7 8 9 10
```

Repeticiones

 Para crear vectores que repitan un valor u otro vector varias veces usamos el comando rep. El primer valor es el objeto a repetir y el segundo es el número de repeticiones:

```
> rep(10,3)
[1] 10 10 10
> rep(c("hola","chao"),4)
[1] "hola" "chao" "hola" "chao" "hola" "chao" "hola" "chao"
```

Problema: Crear una secuencia que repita 3 veces los 4 primeros múltiplos de 7.

```
> rep(seq(from=7,by=7,length=4),3)
[1] 7 14 21 28 7 14 21 28 7 14 21 28
```

Generación de vectores aleatorios

- Para realizar experimentos o simular fenómenos de comportamiento conocido es muy útil generar vectores aleatorios.
- Si queremos números uniformemente distribuidos entre un máximo y un mínimo usamos runif:

```
> runif(n=5, min = 1, max = 10)
[1] 5.058862 1.737830 9.450956 9.149376 2.652774
```

• Si queremos números centrados en una media μ y con una desviación estándar σ , usamos una distribución normal con **rnorm** donde sabemos que el 68 % de las observaciones estarán alrededor $\mu \pm \sigma$, el 95 % en $\mu \pm 2\sigma$ y el 99,7 % en $\mu \pm 3\sigma$:

```
> rnorm(n=5, mean = 10, sd = 4)
[1] 12.081286  2.636001 16.001953  0.120463  6.211835
```

Generación de vectores aleatorios (2)

• Cuando queremos modelar un número de arribos por unidad de tiempo para simular modelos de colas, usamos la distribución de **Poisson** con **rpos**. El parámetro λ nos dice la cantidad promedio de llegadas en un período:

```
> rpois(n=10, lambda = 3)
[1] 1 3 8 6 1 1 6 3 4 7
```

• Un experimento de distribución binomial se basa en tener n experimentos, donde en cada experimento realizamos k intentos de un fenómeno cuya probabilidad de acierto en cada intento es p. Con el comando rbinom podemos simular la cantidad de aciertos obtenidos en cada experimento.

```
> rbinom(n=10,size=2,prob=0.5)
[1] 0 1 2 1 1 0 2 0 0 1
> rbinom(n=10,size=2,prob=0.7)
[1] 1 2 2 1 0 1 2 2 2 2
> rbinom(n=10,size=2,prob=0.2)
[1] 0 0 0 0 1 0 1 0 1 0
```

Variables Categóricas o Factores

- Además de las variables numéricas o lógicas, se puede trabajar con variables categóricas. Ej: color, sexo, clase social.
- Se crean con el comando factor y los posibles valores de la variable se guardan en el atributo levels.

```
> gente<-factor(c("Hombre","Mujer","Mujer","Mujer","Hombre"))
> gente
[1] Hombre Mujer Mujer Mujer Hombre
Levels: Hombre Mujer
> class(gente)
[1] "factor"
> levels(gente)
[1] "Hombre" "Mujer"
#Puedo renombrar a los niveles
> levels(gente)<-c("Man","Woman")
> gente
[1] Man Woman Woman Man
Levels: Man Woman
```

Agregando variables por categorías con tapply

- Si tenemos un vector numérico y otro categórico del mismo largo podemos aplicar una función de agregación.
- Ejemplo: Creo una categoría para el vector edades de niveles niño, adolescente, adulto:

 Ahora cuento la cantidad de personas por categoría, y calculo la media y la desviación estándar para cada grupo:

Manejo de Strings

Puedo imprimir un string usando el comando cat:

```
> saludo<-"Hola Mundo"
> cat(saludo)
Hola Mundo
```

Para concatenar dos strings uso el comando paste:

```
> paste("Hola","Chao",sep="-")
[1] "Hola-Chao"
> paste("persona",1:4, sep="")
[1] "personal" "persona2" "persona3" "persona4"
> paste(saludo,1:3, sep=" ")
[1] "Hola Mundo 1" "Hola Mundo 2" "Hola Mundo 3"
```

Para extraer sub-cadenas usamos el comando substr:

```
> substr(saludo,1,4)
[1] "Hola"
```

 Existe un vector llamado letters que tiene todas las letras del abecedario, útil para nombrar variables:

```
> letters[1:4]
[1] "a" "b" "c" "d"
```

Matrices

 Las matrices son vectores de dos dimensiones. Por defecto se van llenando por columna:

Para llenarlas por fila uso el parámetro byrow:

Accedemos a la dimensión de la matriz con el comando dim.

```
> dim(matriz_por_fil)
[1] 4 3
```

Matrices (2)

Para acceder a los elementos de una matriz tengo que especificar las filas i y las columnas j [i, j]. Si dejo alguno de los dos valores vacío se recuperan todos las filas o columnas:

 Para acceder a los nombres de las filas o columnas usamos rownames y colnames de forma análoga a como usamos names para los vectores.

```
> rownames (matriz_por_fil) <-paste("r",1:4, sep="")
> colnames (matriz_por_fil) <-paste("c",1:3, sep="")
> matriz_por_fil["r2","c3"]
[1] 6
```

Matrices (3)

Puedo agregarle nuevas filas o nuevas columnas a una matriz usando rbind y cbind respectivamente:

```
> rbind(matriz_por_fil,r5=1:3)
    c1 c2 c3
r1 1 2 3
r2 4 5 6
r3 7 8 9
r4 10 11 12
r5 1 2 3
> cbind(matriz_por_fil,c4=4:1)
    c1 c2 c3 c4
r1 1 2 3 4
r2 4 5 6 3
r3 7 8 9 2
r4 10 11 12 1
```

Matrices (4)

Operaciones algebraicas como la multiplicación de matrices se hace con % * %:

```
>a<-matriz_por_col %*% matrix_por_fil
c1 c2 c3
[1,] 166 188 210
[2,] 188 214 240
[3,] 210 240 270
```

 Si usamos solamente el operador *, la multiplicación se hace elemento por elemento (sólo para matrices de igual dimensión). Esto aplica también para la suma, la resta, la división y otro tipo de operadores.

Matrices (5)

Podemos transponer una matriz con t:

```
> t(a)
    [,1] [,2] [,3]
c1 166 188 210
c2 188 214 240
c3 210 240 270
```

Los valores y vectores propios se calculan con eigen:

Arreglos

Los arreglos son como las matrices pero de más dimensiones:

```
> arreglo<-array(1:8, dim=c(2,2,2))
> arreglo
, , 1
    [,1] [,2]
[1,] 1 3
[2,] 2 4
, , 2
    [,1] [,2]
[1,] 5 7
[2,] 6 8
> arreglo[1,2,1]
[1] 3
```

Listas

- Las matrices me restringen a que todos los vectores sean del mismo largo y del mismo tipo.
- Las listas me permiten agrupar objetos de cualquier tipo y de cualquier largo:

• Cuando accedo a sus elementos usando [i] recupero una sub-lista:

```
> milista[c(3,4)] # Sublista
$hijos
[1] 3
$edades
[1] 4 8 12
```

Para acceder a una elemento particular tengo tres opciones:

```
milista[[1]]
milista[["hombre"]]
milista$hombre

[1] "Pepe"
```

Ejercicio Lista

 Crear una lista que tenga tres vectores de largo 100 generado por alguno de los mecanismos vistos para generar vectores aleatorios. Pueden variar las distribuciones o los parámetros. Asígnele nombres a cada uno de los vectores.

Calcule la media y la desviación estándar de cada uno de los vectores de la lista.

```
medias<-vector()
desv<-vector()
for(i in 1:length(vectores)){
   medias[i]<-mean(vectores[[i]])
   desv[i]<-sd(vectores[[i]])
}
> medias
[1] 10.589222 10.390000 9.579866
> desv
[1] 5.155478 2.711349 2.905810
```

Cálculos agregados a Listas con sapply y lapply

- El ejercicio anterior se puede resolver de manera mucho más sencilla en R con unas funciones especiales para realizar agregación sobre listas.
- El comando sapply permite aplicar una función a cada elemento de una lista y devuelve los resultados en un vector. Luego lapply hace lo mismo pero retorna una lista:

```
> sapply(vectores,mean)
  normal poisson uniforme
10.589222 10.390000 9.579866
> sapply(vectores,sd)
  normal poisson uniforme
5.155478 2.711349 2.905810
```

 Ejercicio, programar una propia versión de sapply. Hint: En R una funciones puede recibir otra función como parámetro y aplicarla de manera genérica.

```
myapply<-function(lista, fun,...) {
  resultado<-vector(length=length(lista))
  for(i in 1:length(lista)) {
    resultado[i]<-fun(lista[[i]],...)
  }
  resultado</pre>
```

Data Frames

- El data.frame es el tipo de colección de datos más utilizada para trabajar con datasets en R.
- Un data.frame se compone de varios vectores, donde cada vector puede ser de distintos tipos, pero del mismo largo. Es equivalente a una tabla de una base de datos:

 Las dimensiones de un data.frame se acceden de la misma manera que en una matriz:

```
> length(edades.frame)
[1] 2
> dim(edades.frame)
[1] 21 2
```

Data Frames (2)

Puedo acceder a los elementos como si fuese una matriz o una lista:

```
> edades.frame[3,1] # La edad del tercer elemento
[1] 12
> edades.frame$edad[1:6] # La edad de los primeros 6 elementos
[1] 21 33 12 34 23 70
```

También puede pasar cada variable del data.frame a mi workspace con el comando attach y así accederlas directamente:

```
attach(edades.frame)
> categoria[1:3]
[1] adulto adulto adolescente
Levels: adolescente adulto niño
```

 Puedo guardar un data.frame en un archivo csv (separado por comas u otra carácter) usando write.table:

```
write.table(x=edades.frame,file="edades.csv",sep=",",row.names=F)
```

 Pongo row.names=F para que no ponga los nombres de las columnas en el archivo

Cargando Data Frames

• Puedo leer un data.frame desde archivos csv de manera nativa y desde otras fuentes (Excel, base de datos, etc.) usando librerías especiales:

```
my.frame<-read.table(file="edades.csv", header=T, sep=",")
```

- El parámetro header específica si quiero usar la primera fila para asignarle nombres a las columnas.
- Además R provee varias colecciones de datos para experimentar. Se pueden ver como el comando data().
- Para ver todos los datasets disponibles de todas las librerías:

```
data(package = .packages(all.available = TRUE))
```

 Ahora podemos cargar un dataset, que se incluye como data.frame en mi workspace:

```
data(USArrests) # Arrestos en Estados Unidos por estado
```

Muestreo

- Cuando tenemos datasets muy grandes algunas técnicas estadísticas o de visualización pueden ser muy costosas computacionalmente.
- Se puede trabajar con una muestra aleatoria de los datos.
- La idea es que si la muestra es representativa, la propiedades observadas serán equivalentes a las de la población.
- En R se realiza el muestreo con el comando sample.
- Si la muestra es sin reemplazo, sacamos datos de manera aleatoria sin reponer el elemento. Entonces la muestra debe ser de menor tamaño que el dataset:

```
> sample(edades, size=4, replace=F)
[11 80 88 12 23
```

Muestreo (2)

 Si la muestra es con reemplazo poddemos observar datos duplicados. De esta forma, la muestra puede ser incluso de mayor tamaño que la colección original:

```
sample (edades, size=100, replace=T)
```

- Cuando tenemos que los datos vienen etiquetados por alguna categoría y tomamos una muestra donde cada categoría tiene una participación proporcional a la de la colección original, tenemos un muestreo estratificado.
- Ejercicio: extraer una muestra aleatoria sin reemplazo que tenga 10 filas del data frame USArrests

```
USArrests[sample(1:(dim(USArrests)[1]),size=10,replace=F),]
```

Instalando librerías adicionales

- R tiene una comunidad muy activa que desarrolla muchas librerías para el análisis y la visualización de datos.
- Se pueden descargar librerías adicionales desde el repositorio CRAN directamente desde R.
- Las librerías se pueden instalar desde Rstudio o con el siguiente comando: install.packages ("rpart", dependencies=T)
- Luego para poder usarlas se cargan de la siguiente forma: library (rpart).

Bilbiografía I



Venables, William N., David M. Smith, and R Development Core Team. *An introduction to R.*, 2002.